

Documentação Metodológica — Tratamento de Dados Ausentes de Precipitação (INMET)

Responsável: Pessoa A — Tratamento de ausentes (imputação, interpolação) **Fonte de dados:** INMET, estações automáticas, região Sudeste, 2008–2022 **Ferramentas:** DuckDB, pandas, Python

Este documento consolida todo o processo de auditoria de qualidade de dados e tratamento de valores ausentes conduzido sobre a série de precipitação horária (`precip_mm`), incluindo os problemas identificados, as decisões metodológicas tomadas e sua justificativa técnica/acadêmica. Serve como material de apoio para a redação da seção de metodologia e para eventuais perguntas de banca sobre a qualidade dos dados utilizados.

1. Objetivo da etapa

Preparar a série histórica de precipitação horária das estações automáticas do INMET na região Sudeste para uso como variável preditora em modelos de aprendizado de máquina voltados à previsão de desastres naturais, garantindo:

- Integridade estrutural dos dados (ausência de erros de processamento silenciosos);
 - Tratamento estatisticamente defensável de valores ausentes, proporcional ao tamanho e à natureza da lacuna;
 - Documentação transparente de toda decisão que afete a completude ou a confiabilidade da série.
-

2. Diagnóstico inicial (pré-existente ao início desta investigação)

Antes da investigação aprofundada, já haviam sido realizadas as seguintes etapas de limpeza, mantidas sem alteração:

1. **Padronização de valores sentinela:** o INMET codifica ausência de leitura como `-9999`. Esses valores foram convertidos para `NULL` em todas as variáveis meteorológicas antes de qualquer análise estatística, evitando que fossem tratados como medições reais (erro comum e grave se não corrigido).
2. **Remoção de duplicatas de 2013:** identificado, por comparação entre `COUNT(*)` e `COUNT(DISTINCT (CODIGO_WMO, DATA, HORA.UTC))`, que o ano de 2013 continha registros integralmente duplicados. Removidos via `SELECT DISTINCT`.
3. **Definição da janela temporal:** com base na cobertura histórica da rede de estações (número de estações ativas por ano), definiu-se o intervalo **2008–2022** como equilíbrio entre extensão temporal e representatividade espacial (70% da cobertura máxima da rede atingida a partir de 2008).

3. Achado 1 — Falha estrutural mascarada de "missing de rede"

3.1 Sintoma observado

Ao calcular a proporção de dados ausentes por estação (`precip_mm IS NULL`), um subconjunto de estações completamente distintas — sem relação geográfica ou administrativa entre si — apresentou **exatamente o mesmo número de horas ausentes** (33.580 horas, $\approx 3,83$ anos) em um relatório de imputação inicial.

3.2 Investigação

A hipótese inicial foi de uma falha de rede/telemetria simultânea afetando múltiplas estações. Para testá-la, comparou-se a interseção dos **timestamps ausentes como valor nulo em linha existente** entre estações — resultado: interseção baixa ($<15\%$ par a par), refutando a hipótese de falha simultânea nesse nível.

O teste correto exigiu diferenciar dois tipos de ausência, distinção pouco discutida na literatura aplicada mas essencial na prática:

- **Ausência de valor** (`NULL` em uma linha existente) — tipicamente falha de sensor pontual.
- **Ausência estrutural** (a linha/hora nunca chega a existir na tabela, só aparece após reindexação para grade horária completa) — pode indicar falha sistêmica na coleta/transmissão.

Repetindo o teste de interseção sobre a ausência **estrutural**, encontrou-se sobreposição de **100% entre todas as estações testadas** — confirmando que as 33.580 horas ausentes eram, de fato, compartilhadas.

3.3 Causa raiz

A partir de **1º de janeiro de 2019**, o formato do campo `HORA_UTC` na fonte mudou de `HH:MM` (ex.: `13:00`) para `HHMM UTC` (ex.: `1300 UTC`). A rotina original de conversão de data/hora (`CASE WHEN ... POSITION(': ' IN HORA_UTC) ...`) não reconhecia o novo formato e atribuía meia-noite a todas as 24 leituras do dia — colapsando 23 das 24 horas diárias em um único timestamp.

Validação quantitativa: antes da correção, a proporção de registros à meia-noite exata era anormalmente alta em 2019–2022; após a correção do parser, ficou em exatamente **1/24 (4,1667%)** em todos os 23 anos da série (2000–2022), valor teoricamente esperado se todas as horas do dia forem igualmente prováveis.

3.4 Correção

Adicionado um novo ramo ao `CASE WHEN` de conversão, extraíndo os dígitos do campo via `REGEXP_REPLACE` e aplicando divisão inteira por 100 (`HHMM / 100 = HH`), robusto a variações de zero-padding.

4. Achado 2 — Revisão de metadados cadastrais do INMET (mesma data, 2019)

Durante a geração da tabela de metadados por estação, identificou-se que **113 estações** apresentavam mais de um valor de (`altitude`) e mais de um formato de (`DATA_FUNDACAO`) ao longo de sua série histórica. Testou-se sistematicamente o ano de início do "segundo" conjunto de valores: **100% das estações afetadas mudam exatamente em 2019** — a mesma data da mudança de formato de (`HORA_UTC`) (Achado 1), porém em campos totalmente distintos (metadado cadastral, não formato de hora).

Essa coincidência exata entre dois achados metodologicamente independentes eleva a conclusão de hipótese a **achado consolidado**: o INMET revisou seu sistema de exportação/consolidação de dados de forma abrangente em janeiro de 2019, afetando tanto formatos de campo quanto valores cadastrais.

Esse tipo de inconsistência — mudança de metadado de estação ao longo do tempo (localização, altitude, data de fundação) sem registro explícito na série — é um problema conhecido e documentado na literatura de climatologia como **descontinuidade não climática (inomogeneidade)**, tratado extensivamente nas diretrizes da Organização Meteorológica Mundial sobre metadados climáticos (AGUILAR et al., 2003). A prática recomendada nessa literatura é justamente a documentação explícita de qualquer mudança de metadado detectada, o que foi seguido aqui.

Política de resolução adotada: uso do valor de metadado (`latitude`), (`longitude`), (`altitude`) mais recentemente registrado por estação, sob a premissa de que revisões cadastrais de órgãos oficiais tendem a corrigir, não degradar, a precisão da informação — premissa razoável, mas não verificável sem documentação oficial do INMET sobre a revisão.

5. Achado 3 — Erro silencioso de agregação em pandas

5.1 Sintoma

Após a implementação da estratégia de imputação por faixa de gap, o relatório indicou (`pct_imputado = 0%`) em todas as 146 estações processadas — resultado estatisticamente implausível dado que a proporção de dados ausentes conhecida era de 8,88%.

5.2 Causa raiz

A etapa de agregação de registros duplicados por timestamp usava (`df.groupby('dt_utc').agg({'precip_mm': 'sum'})`). O comportamento padrão do método (`.sum()`) do pandas é retornar (`0.0`), não (`NaN`), para grupos onde todos os valores são ausentes (parâmetro (`min_count=0`) por padrão) — convertendo silenciosamente **todo** valor ausente em zero antes mesmo da lógica de imputação ser executada.

5.3 Correção e validação

Corrigido com `df.groupby('dt_utc')['precip_mm'].sum(min_count=1)`. Validado por uma checagem de sanidade **externa** (não apenas consistência interna do relatório): comparação do `pct_missing` agregado do relatório de imputação contra o mesmo valor calculado independentemente via SQL direto na tabela-fonte — resultado idêntico (8,88% vs. 8,88%, diferença de 0,00 pontos percentuais).

Esse episódio ilustra um princípio de engenharia de dados relevante para a seção de metodologia: **checagens de consistência interna não substituem validação contra uma referência externa e independente**, pois um erro que ocorre antes do ponto de checagem pode manter a lógica downstream internamente coerente e, ainda assim, produzir um resultado incorreto.

6. Estratégia de imputação por faixa de tamanho de gap

Em vez de aplicar uma única técnica de imputação uniformemente, os gaps foram classificados por duração e tratados de forma diferenciada, seguindo a lógica de que **a confiabilidade de qualquer método de preenchimento decai com o tamanho do gap**, especialmente para variáveis intermitentes como precipitação (SIMOLO et al., 2010; MARTINS et al., 2023):

Classe	Duração	Método	Justificativa
Curto	≤ 6 h	Interpolação linear (<code>method='time'</code>)	Gaps curtos em variáveis meteorológicas contínuas são adequadamente aproximados por interpolação simples.
Médio	6–48 h	Forward-fill / backward-fill (limite de 48h em cada direção)	Estudo de comparação de métodos de gap-filling para séries de precipitação diária no Brasil (bacias PCJ, SP) encontrou desempenho aceitável de métodos de regressão/interpolação para gaps de até 7 dias consecutivos, com degradação acentuada além disso (MARTINS et al., 2023) — o limite de 48h aqui adotado é, portanto, conservador em relação ao que a literatura considera aceitável.
Longo	48h – 30 dias	Não imputado (mantido como <code>NaN</code>), sinalizado para decisão manual	Risco de introduzir padrões artificiais (ex.: "chuviscos" em períodos secos) supera o benefício de completude, dado o comportamento intermitente e não-gaussiano da precipitação (SIMOLO et al., 2010).
Extremo	> 30 dias	Não imputado; estação avaliada para segmentação ou exclusão	Gaps dessa magnitude tipicamente indicam falha de equipamento prolongada, não ruído amostral — tratados como limitação estrutural da série, não como lacuna a preencher.

Essa classificação de mecanismo de ausência remete à taxonomia clássica de LITTLE; RUBIN (2019) — ausência completamente aleatória (MCAR), ausência aleatória condicional (MAR) e ausência não-aleatória (MNAR). Gaps curtos/médios dispersos são consistentes com um mecanismo aproximadamente MCAR (falha eletrônica pontual, sem relação com o valor da variável); gaps longos/extremos concentrados temporalmente levantam a possibilidade de MNAR (falha de equipamento correlacionada a fatores não observados, como manutenção de campo) — hipótese discutida na seção 8, não comprovada com os dados disponíveis.

Correção metodológica adicional: a implementação inicial de forward/backward-fill continha uma falha ao localizar apenas o *maior* bloco contíguo de ausência por estação para fins de corte, deixando intactos outros gaps longos igualmente problemáticos em estações com múltiplas falhas dispersas (ex.: uma estação com 19 blocos de gap longo/extremo permaneceu com 20% de dado ausente mesmo após o corte do maior bloco). Corrigido para identificar **todos** os blocos (`longo`)/(`extremo`) e selecionar o maior intervalo contíguo livre de qualquer um deles — validado até zerar o resíduo de ausência não-intencional (`pct_nan_residual_pos_corte = 0,00%`) em todas as estações reprocessadas).

7. Critérios de exclusão de estações

Dois critérios de exclusão foram aplicados, em momentos distintos do processo:

7.1 Exclusão por proporção de ausência (pré-imputação)

Estações com $\text{pct_missing} > 30\%$ (calculado sobre dados já corrigidos, ver seção 3) foram excluídas antes da imputação: **S122, A560, A766, A746, A767, A765** (6 de 152 estações).

7.2 Exclusão por instabilidade operacional crônica (pós-imputação)

Entre as estações com gaps longos/extremos, 15 exigiram segmentação (uso apenas do maior trecho contínuo livre de gaps grandes). Dessas, aplicou-se um critério adicional: **exclusão se número de blocos de gap longo/extremo > 15 OU se o trecho remanescente for menor que 3 anos** — indicando instabilidade crônica do equipamento ao longo de toda a vida útil da estação, não um evento isolado.

Resultado: **A610** (33 blocos), **A737** (19 blocos), **A546** (17 blocos) e **A764** (segmento remanescente de apenas 1,6 anos) foram excluídas por esse critério.

Nota de precisão metodológica: este critério de exclusão é uma recomendação de boa prática estatística, não uma instrução explícita da orientação recebida sobre o projeto — é importante que essa distinção conste no texto do TCC, para que a justificativa da decisão não seja atribuída incorretamente a uma fonte externa.

8. Resultado consolidado e limitações identificadas

Métrica	Valor
Estações no dataset bruto (região Sudeste)	152
Estações no dataset final	142
Total de registros (estação-hora) no dataset final	14.609.670
Perda total de dado em relação ao cenário sem nenhum corte de qualidade	7,95%
pct_missing do dataset final (validado externamente)	8,88%

Limitações a declarar explicitamente no texto do TCC

1. **Cobertura espacial variável no tempo:** o número de estações ativas por ano varia entre 97 (2008) e 132 (2018-2019), refletindo tanto o crescimento histórico da rede do INMET quanto o efeito residual das exclusões por qualidade. Isso significa que a densidade espacial de observação não é constante ao longo do período de estudo —

relevante para qualquer análise que dependa de comparação simultânea entre estações.

2. **Estações segmentadas cobrem períodos distintos entre si:** as 11 estações mantidas via segmentação têm janelas temporais válidas diferentes umas das outras (ex.: uma cobre até 2013, outra até 2019) — não formam um painel temporal balanceado.
 3. **Hipótese não testada de ausência informativa (MNAR):** não foi verificado se os períodos de falha de equipamento coincidem com eventos de precipitação extrema em estações vizinhas — se houver essa correlação, a imputação/exclusão de tais períodos poderia estar sistematicamente subestimando exatamente os eventos mais relevantes para um sistema de alerta precoce. Recomenda-se esse teste como extensão futura, caso haja tempo hábil.
 4. **Escopo desta etapa restrito à variável** `(precip_mm)`: as demais variáveis meteorológicas potencialmente preditoras (temperatura, umidade, vento, pressão) não passaram por tratamento de ausentes equivalente até o momento da redação deste documento.
-

9. Sugestões de tabelas e gráficos para o TCC

- **Tabela:** distribuição de `(pct_imputado)` por estação (estatística descritiva: média, mediana, desvio-padrão, min/máx) — evidencia transparência sobre a proporção de dado sintético no dataset final.
 - **Tabela:** lista de estações excluídas com motivo (proporção de ausência vs. instabilidade crônica) — Seções 7.1 e 7.2 já fornecem os dados brutos.
 - **Gráfico de linha:** número de estações ativas por ano (2008–2022) — evidencia visualmente a limitação de cobertura temporal desigual (Seção 8, limitação 1).
 - **Gráfico antes/depois:** série temporal de 3–5 estações representativas (uma de alta qualidade, uma segmentada, uma com gap longo visível) mostrando o dado observado vs. imputado, com cores distintas por método (`(linear_6h)`, `(fb_48h)`, `(NaN)` residual).
 - **Linha do tempo:** um diagrama simples situando os três achados de qualidade de dados (parsing de `(HORA.UTC)`, revisão de metadados, bug de agregação) na linha do tempo do projeto — reforça visualmente a narrativa de investigação rigorosa.
-

10. Referências

AGUILAR, Enric et al. **Guidelines on climate metadata and homogenization**. Geneva: World Meteorological Organization, 2003. (WMO/TD-No. 1186, WCDMP-No. 53).

LITTLE, Roderick J. A.; RUBIN, Donald B. **Statistical analysis with missing data**. 3. ed. Hoboken: Wiley, 2019.

MARTINS, Letícia Lopes et al. Gap-filling of daily precipitation and streamflow time series: a method comparison at random and sequential gaps. **Hydrological Sciences Journal**, v. 68,

n. 1, p. 148-160, 2023.

SIMOLO, Claudia et al. Improving estimation of missing values in daily precipitation series by a probability density function-preserving approach. **International Journal of Climatology**, v. 30, n. 10, p. 1564-1576, 2010.

VAN BUUREN, Stef. **Flexible imputation of missing data**. 2. ed. Boca Raton: CRC Press, 2018.

WORLD METEOROLOGICAL ORGANIZATION (WMO). **Guide to climatological practices**. 3. ed. Geneva: WMO, 2010. (WMO-No. 100).

Nota: as referências acima foram verificadas via busca (título, autoria, veículo e ano conferidos) antes da inclusão neste documento. MARTINS et al. (2023) é um estudo brasileiro aplicado à bacia PCJ (SP), atendendo à recomendação da orientação de incluir ao menos uma referência nacional aplicada.