

README — `metadados_estacoes.csv`

Tabela de referência com uma linha por estação meteorológica do INMET, consolidando identificação, geolocalização, período de dados válido e indicadores de qualidade — já considerando todas as correções e decisões tomadas na etapa de tratamento de ausentes (Pessoa A, semana 2).

Use esse arquivo como ponto de entrada para qualquer cruzamento com a base do CEMADEN (integração de ocorrências de desastre) ou para decidir quais estações usar em análises espaciais.

1. Como carregar

```
python

import pandas as pd

meta = pd.read_csv("metadados_estacoes.csv", parse_dates=[
    "periodo_valido_inicio", "periodo_valido_fim"
])
```

2. Dicionário de colunas

Identificação e geolocalização

Coluna	Tipo	Descrição
<code>CODIGO_WMO</code>	texto	Identificador único da estação (ex.: <code>A705</code>). Chave primária desta tabela.
<code>ESTACAO</code>	texto	Nome da estação/município de instalação.
<code>UF</code>	texto	Unidade federativa (sigla, ex.: <code>SP</code>).
<code>REGIAO</code>	texto	Região do Brasil (nesta base, sempre <code>SE</code> — recorte Sudeste do projeto).
<code>latitude</code>	float	Graus decimais, WGS84 (EPSG:4326) .
<code>longitude</code>	float	Graus decimais, WGS84 (EPSG:4326) .
<code>altitude</code>	float	Metros acima do nível do mar.
<code>DATA_FUNDACAO</code>	texto	Data de instalação da estação. ⚠ Formato misto — ver seção 4.

Importante: `latitude`/`longitude`/`altitude` são o **valor mais recente registrado** para cada estação, não uma média nem o primeiro valor encontrado. Isso importa porque identificamos que a INMET revisou o cadastro de 113 estações em **janeiro de 2019** (mesma data de outra mudança de formato já documentada nesta investigação — ver seção 5). A diferença é pequena em lat/lon (~metros), mas pode chegar a **~30 metros em altitude** para algumas estações. Se você comparar essa tabela com uma versão antiga do metadado ou com outra fonte que use o cadastro pré-2019, espere pequenas divergências — isso é esperado e documentado, não erro.

Período de cobertura e qualidade do dado

Coluna	Tipo	Descrição
<code>periodo_valido_inicio</code>	datetime	Primeiro timestamp horário válido da estação no dataset final (pode ser diferente do início histórico real, se a estação foi segmentada — ver <code>foi_segmentada_tier_c</code>).
<code>periodo_valido_fim</code>	datetime	Último timestamp horário válido da estação no dataset final.
<code>total_horas_validas</code>	int	Total de linhas (horas) no arquivo final da estação.
<code>n_observado</code>	int	Quantas dessas horas são medição real (não imputada).
<code>n_imputado</code>	int	Quantas horas foram preenchidas por interpolação linear (gap ≤6h) ou ffill/bfill (gap ≤48h).
<code>n_nan_residual</code>	int	Horas que permanecem como <code>NaN</code> de propósito (gaps classificados como <code>longo</code> / <code>extremo</code> , não imputados).
<code>pct_imputado</code>	float	<code>n_imputado / total_horas_validas</code> , em %.
<code>foi_segmentada_tier_c</code>	bool	<code>True</code> se a série passou pelo processo de corte/segmentação por ter tido um gap grande demais para imputar (ver seção 5). Se <code>True</code> , o período coberto é menor que o histórico completo da estação — sempre confira <code>periodo_valido_inicio</code> / <code>periodo_valido_fim</code> antes de assumir cobertura total.

Status final e qualidade consolidada

Coluna	Tipo	Descrição
<code>status_final</code>	texto	<code>incluida</code> (está no dataset final, use normalmente) ou <code>excluida_cronica</code> (removida por instabilidade operacional)

Coluna	Tipo	Descrição
— não vai ter arquivo de dados correspondente).		
<code>motivo_exclusao_final</code>	texto	Preenchido só para as excluídas (ex.: <code>"instabilidade cronica (33 obstaculos longo/extremo)"</code>).
<code>qualidade_geral</code>	texto	Classificação resumida para decisão rápida — ver tabela abaixo.

Valores possíveis de `qualidade_geral`:

Valor	Significado	Recomendação de uso
<code>alta</code>	≤5% de dado imputado, série completa	Uso direto, sem ressalvas
<code>media</code>	5-15% de dado imputado, série completa	Usável, mencionar no texto que existe imputação moderada
<code>baixa</code>	>15% de dado imputado, série completa	Usar com cautela; considerar peso menor em agregações espaciais
<code>boa_com_ressalva</code> (serie segmentada, periodo reduzido)	Série foi cortada — o dado que sobrou é de boa qualidade, mas cobre um período mais curto que o histórico total da estação	Uso direto dentro do <code>periodo_valido_inicio</code> / <code>_fim</code> ; não assumir dado antes/depois desse intervalo
<code>excluida</code>	Não está no dataset final	Não usar; presente na tabela só para rastreabilidade

3. Exemplos de uso

Filtrar só estações de alta confiabilidade

```
python

alta_qualidade = meta[meta['qualidade_geral'] == 'alta']
```

Encontrar a estação mais próxima de uma coordenada (ex.: um registro do CEMADEN)

```
python
```

```
import numpy as np

def estacao_mais_proxima(lat_evento, lon_evento, data_evento, meta_df):
    candidatas = meta_df[
        (meta_df['status_final'] == 'incluida') &
        (meta_df['periodo_valido_inicio'] <= data_evento) &
        (meta_df['periodo_valido_fim'] >= data_evento)
    ].copy()
    # Distância aproximada (graus) -- para produção, usar geopy/haversine real
    candidatas['dist'] = np.sqrt(
        (candidatas['latitude'] - lat_evento)**2 +
        (candidatas['longitude'] - lon_evento)**2
    )
    return candidatas.sort_values('dist').iloc[0]
```

Atenção: o filtro por `periodo_valido_inicio`/`_fim` é essencial aqui — sem ele, você pode escolher uma estação que fisicamente existe, mas não tinha dado válido na data do evento (especialmente relevante para as `boa_com_ressalva`, que têm janelas de tempo reduzidas).

Carregar o arquivo de dados horários de uma estação

```
python

codigo = "A705"
df_estacao = pd.read_parquet(f"imputed_by_station_final/chuvas_{codigo}.parquet")
```

Normalizar `DATA_FUNDACAO` (formato misto — ver seção 4)

```
python

meta['data_fundacao_parsed'] = pd.to_datetime(
    meta['DATA_FUNDACAO'], format='mixed', dayfirst=True, errors='coerce'
)
```

4. Limitação conhecida: `DATA_FUNDACAO` em formato misto

Esse campo vem em dois formatos diferentes dependendo de quando a estação teve seu último registro:

- **ISO** (`AAAA-MM-DD`): estações cujo último registro é anterior a 2019
- **BR** (`DD/MM/AA`) ou vazio: estações com registro a partir de 2019

Isso é resultado direto da mesma revisão de sistema da INMET descrita na seção 5 — **não** é erro deste pipeline. `DATA_FUNDACAO` não é usada em nenhum cálculo de série temporal do

projeto; é só metadado informativo. Se for usar (ex.: para calcular "idade da estação" como feature), normalize com `pd.to_datetime(..., format='mixed', dayfirst=True)` antes.

5. Contexto: por que essa tabela existe (resumo da investigação)

Para quem está vendo isso pela primeira vez (ex.: a dupla que trabalha na integração com CEMADEN), esse metadado não é o dado bruto da INMET — ele é resultado de uma investigação de qualidade de dados que encontrou e corrigiu:

1. **Bug de parsing de timestamp:** a partir de 2019, o campo `HORA_UTC` mudou de formato (`13:00` → `1300 UTC`) e não era reconhecido pelo parser original, fazendo 23 das 24 horas de cada dia colapsarem no mesmo timestamp. Corrigido.
2. **Bug de agregação:** `groupby().sum()` no pandas transformava valores ausentes em zero silenciosamente. Corrigido com `min_count=1`.
3. **Revisão de cadastro da INMET em 2019:** confirmada em 113 estações — mudança de altitude cadastral e formato de `DATA_FUNDACAO` na mesma data do bug de `HORA_UTC` acima. Não é um bug do pipeline, é uma mudança na fonte original.
4. **Gaps estruturais grandes:** 15 estações tinham blocos de ausência longos demais para imputação segura. Foram segmentadas (mantendo só o maior trecho contínuo sem gaps grandes) ou excluídas (4 delas, por instabilidade operacional crônica — muitos blocos de falha espalhados pela série).

Resultado: de 152 estações brutas, **142 compõem o dataset final**, com 7,95% de perda total de dado em relação ao cenário sem nenhum corte de qualidade — considerado aceitável e documentado.

6. Perguntas frequentes

"Por que uma estação que eu esperava ver não está aqui?" Verifique `status_final`. Se for `excluida_cronica`, veja `motivo_exclusao_final`. Os arquivos parquet dessas estações continuam existindo (em pasta separada, para rastreabilidade), mas não fazem parte do dataset final recomendado.

"Posso confiar no período completo 2008-2022 pra todas as estações?" Não — confira sempre `periodo_valido_inicio`/`periodo_valido_fim` por estação. Estações com `foi_segmentada_tier_c = True` têm janela reduzida.

"O que fazer se eu precisar de uma variável meteorológica além de `precip_mm`?" Essa tabela e o pipeline de imputação documentado cobrem só precipitação até o momento. Se temperatura/umidade/vento/pressão entrarem no escopo do modelo, elas ainda precisam do mesmo tratamento de ausentes — confirme com o grupo antes de assumir que já estão prontas.